정인수 Insoo Chung

AI Research Scientist · AIRS Medical

insoo_chung@snu.ac.kr
17522chung.github.io

저는 모델 개발을 첫 라벨링부터 제품 출시까지 end-to-end로 담당해왔습니다.
복잡한 task에서 성능을 평가하는 데 익숙합니다.

프로젝트

프로젝트	내 역할	결과
비선형 정합 없이 Brain DTI biomarker 값을 측정하는 상품 개발	ML pipeline 단독 개발, RSNA 2026 제1저자	학계의 standard practice 대비 repeatability 3.5배, 속도 약 10배, FDA 승인 절차 진행 중
DiffBMP: Differentiable Rendering with Bitmap Primitives	동영상으로 제안 기술 적용을 확장, CVPR 2026 공저	temporal flicker (tLP) 53% 감소
Spine MRI 병변 segmentation 모델 초기 개발을 위한 효율적인 pseudo-label 생성	임상 측정 항목 정의부터 모델 개발까지 단독 구축, 진행 중	수작업 없이 픽셀 라벨 (segmentation label) 생성, pseudo-label 툴킷 팀 내 도입
Brain volumetry 모델의 acquisition shift robustness 향상	문제 분석부터 수정까지 주도	benchmark와 수정 모두 제품 반영
Ground truth가 없는 task에서 모델 평가	evaluation harness 구축	팀의 개발 기준을 geometry 최적화에서 샘플링된 값 평가로 전환
개인 프로젝트 2건	VLM, generative model	진행 상태를 각 장에 표기

논문

CVPR 2026 · **DiffBMP: Differentiable Rendering with Bitmap Primitives.** S. Hong*, J. Kim*, D. Kim, **I. Chung**, S. Y. Chun. arXiv:2602.22625 · diffbmp.com

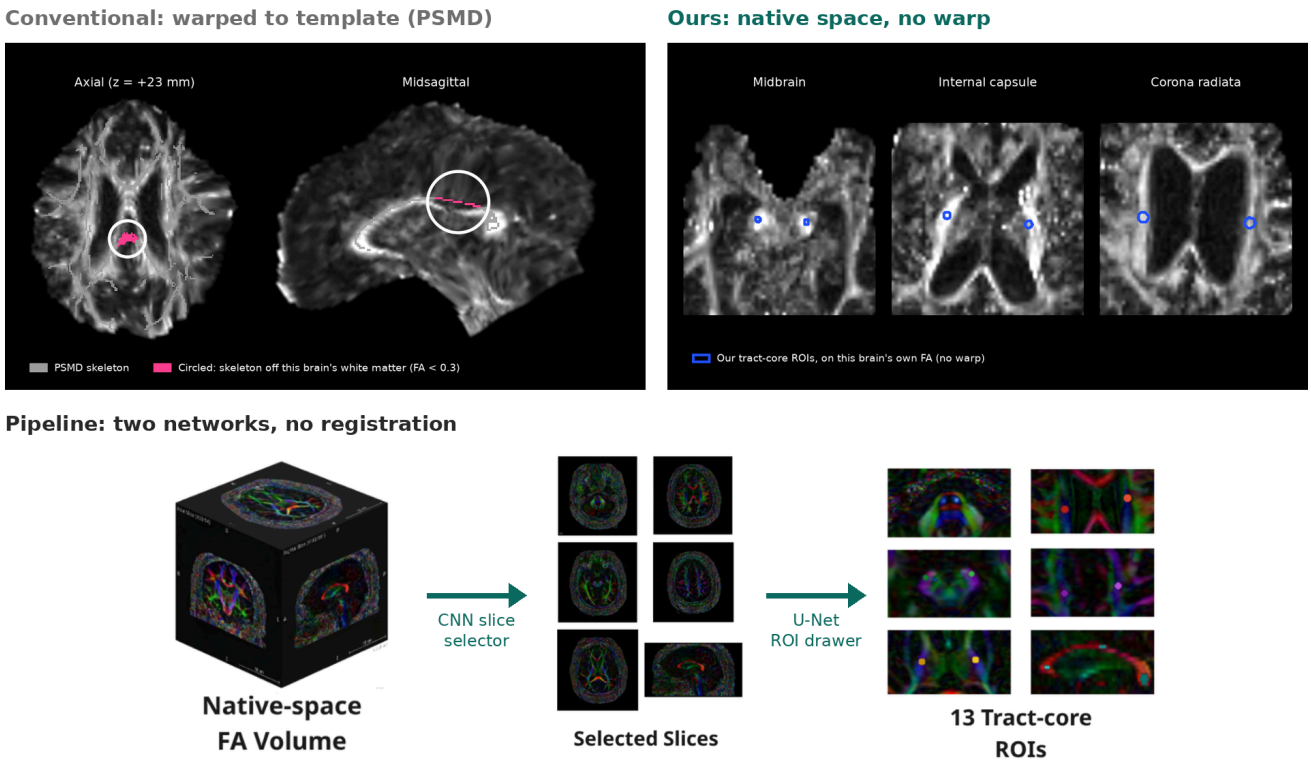
RSNA 2026 · **Native-Space Deep Learning for Reproducible Diffusion MRI Biomarkers of Cognitive Impairment without Spatial Normalization. I. Chung**, W. Jung, J. H. Lee. Scientific presentation, 제1저자

회사 프로젝트는 공개 가능한 범위까지만 담았습니다. 세부 방법과 내부 수치는 회사 정책에 따라 제외했습니다.

End-to-end pipeline · RSNA 2026 제1저자 · AIRS Medical

비선형 정합 없이 Brain DTI biomarker 값을 측정하는 상품 개발

뇌를 template에 비선형 정합하면 edge case들에서 diffusion MRI biomarker가 부정확해지는 문제 발생 → 정합 단계 없이 biomarker 값을 샘플링하는 모델을 설계



문제 학계의 standard practice 방법론들은 각 뇌를 template에 비선형 정합한 뒤 측정합니다. 이 단계는 임상적으로 가장 중요한 뇌 위축 환자(cognitively impaired)에서 실패하며 부정확한 biomarker 값을 내놓게 됩니다.

내가 한 일 정합을 생략할 수 있다는 가설을 세우고, 네트워크가 각 스캔의 native space에서 white matter tract core 13곳을 찾도록 했습니다. slice selection, ROI regression, age-·sex-normed percentile, GPU tractography까지 ML pipeline 전체를 구축했습니다. ROI drawer는 U-Net 기반으로 **여러 아키텍처를 직접 설계하고 비교**했습니다.

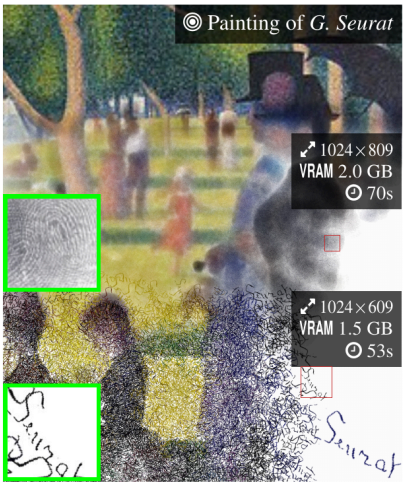
결과 공개 데이터의 repeat-scan **784쌍**에서 표준 marker인 PSMD보다 **repeatability가 3.5배** 높고(±11.2% vs ±39.8%) **약 10배 빠릅니다**(9초 vs 89초). 대신 discrimination은 소폭 낮습니다(AUC 0.80 vs 0.84). 해당 biomarker 측정 모델은 현재 FDA 승인 절차를 진행 중입니다.

Figure: RSNA 2026 발표 자료. OASIS-3 데이터는 OASIS 데이터 사용 협약에 따라 사용.

Differentiable rendering · CVPR 2026 공저 · 서울대 ICL

DiffBMP: Differentiable Rendering with Bitmap Primitives

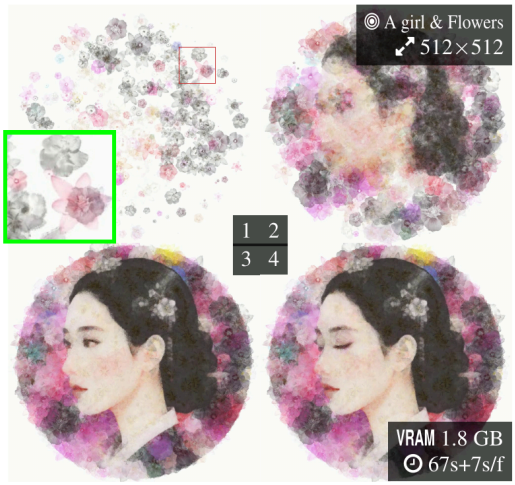
DiffBMP를 연속적인 프레임에 적용하면 temporal flicker가 발생하는 문제 → warm start, stuck primitive 제거, freeze로 동영상까지 적용을 확장



(a) Image composition with 3000 fingerprints / 2000 autographs



(b) Intrinsic-preserving graphic assemblage with 300 logos



(c) Video composition under spatial constraint w/ 2000 flowers, followed by post-processing

Fig. 2 Framework

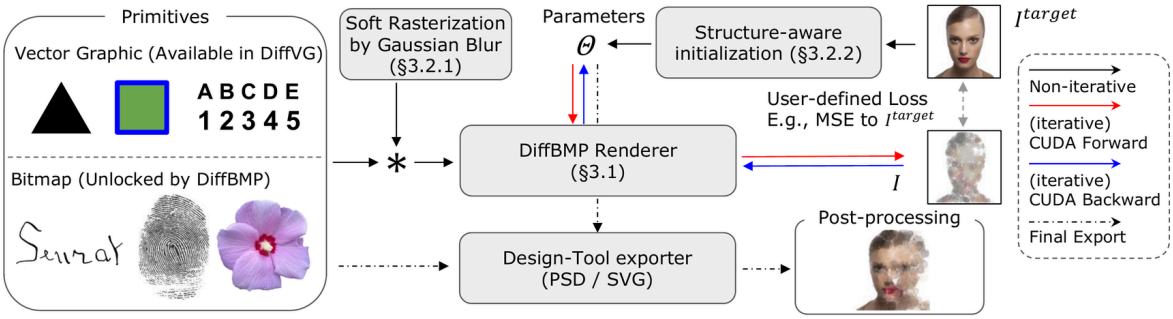


Fig. 4 Dynamic DiffBMP (my work)



(a) Target Frame (b) Initialized from $\Theta^{f-1\star}$ (c) (b) + Removing Stuck primitives

Table 4 Dynamic DiffBMP ablation, 17 videos

Init. $\Theta^{f-1\star}$	Rem. Stk.	Freez. Unch.	Frame-wise Fidelity PSNR↑	Frame-wise Fidelity SSIM↑	Anti-flicker tLP↓	Anti-flicker tOF↓
✗	✗	✗	$24.19_{\pm 2.36}$	$0.616_{\pm 0.106}$	$7.41_{\pm 8.89}$	$2.23_{\pm 1.10}$
✓	✗	✗	$24.26_{\pm 1.73}$	$0.629_{\pm 0.073}$	$5.39_{\pm 4.64}$	$1.88_{\pm 1.13}$
✓	✓	✗	$24.66_{\pm 2.03}$	$0.647_{\pm 0.088}$	$4.98_{\pm 4.93}$	$1.89_{\pm 1.11}$
✓	✗	✓	$24.23_{\pm 2.13}$	$0.617_{\pm 0.099}$	$3.50_{\pm 2.52}$	$1.91_{\pm 1.32}$
✓	✓	✓	$24.38_{\pm 2.23}$	$0.630_{\pm 0.069}$	$3.49_{\pm 2.26}$	$1.84_{\pm 1.19}$

내 기여 해당 논문에서 제시한 방법론(DiffBMP)을 연속적인 프레임인 동영상에서도 적용할 수 있도록 하는 **Dynamic DiffBMP**를 맡았습니다. 이전 프레임으로 warm start하고, gradient를 막는 stuck primitive를 제거하고, 변화 없는 영역을 freeze했습니다. structure-aware initialization에도 기여했습니다.

결과 동영상 17개에서 fidelity 손실 없이 **temporal flicker (tLP)를 53% 줄였습니다**.

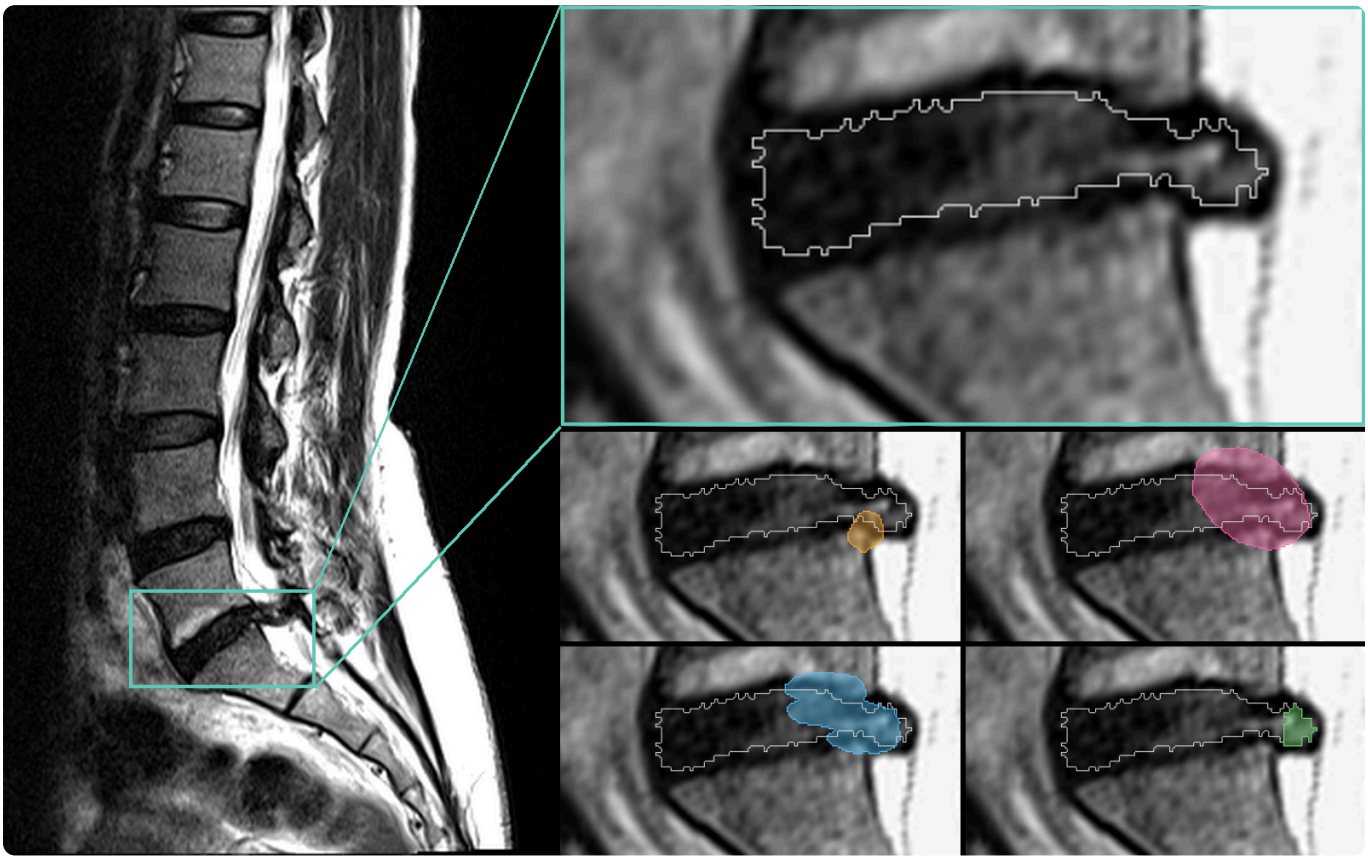
원인 분석 프레임의 품질을 해치는 primitive가 여러 per-pixel gradient의 충돌로 local optimum을 빠져나가지 못하고 있다는 가설을 세웠습니다. 따라서 per-pixel gradient magnitude로 순위를 매기는 방식을 후속 작업으로 구현했습니다(미발표).

Figure: DiffBMP 논문 Fig. 1, Fig. 2, Fig. 4, Table 4. arXiv · diffbmp.com · github.com/smhongok/diffbmp

Weak supervision · AIRS Medical

Spine MRI 병변 segmentation 모델 초기 개발을 위한 효율적인 pseudo-label 생성

open dataset에 병변 segmentation label이 없는 문제 발생 → classification label에서 pseudo-label을 생성해 첫 모델을 학습하고, annotator는 모델의 예측을 수정하기만 하면 flywheel이 굴러가는 구조를 설계



문제 Spine MRI 제품을 단독으로 개발하고 있으며, 임상적으로 중요한 측정 항목을 정하는 일부터 시작했습니다. 병목은 라벨이었습니다. open dataset에는 디스크별 이상 여부(classification label)만 있지, 이상 부위와 병변에 대한 segmentation label이 없었습니다.

내가 한 일 여러 weakly supervised 기법으로 classification label을 **수작업 없이 픽셀 라벨 (segmentation label)**로 변환했습니다. 해당 pseudo-label로 모델이 학습을 마친 후에는 모델이 낸 mask를 일부만 수정해도 쓸 만한 mask가 되고, 그 결과로 다음 모델을 학습하는 human-in-the-loop 구조로 설계했습니다.

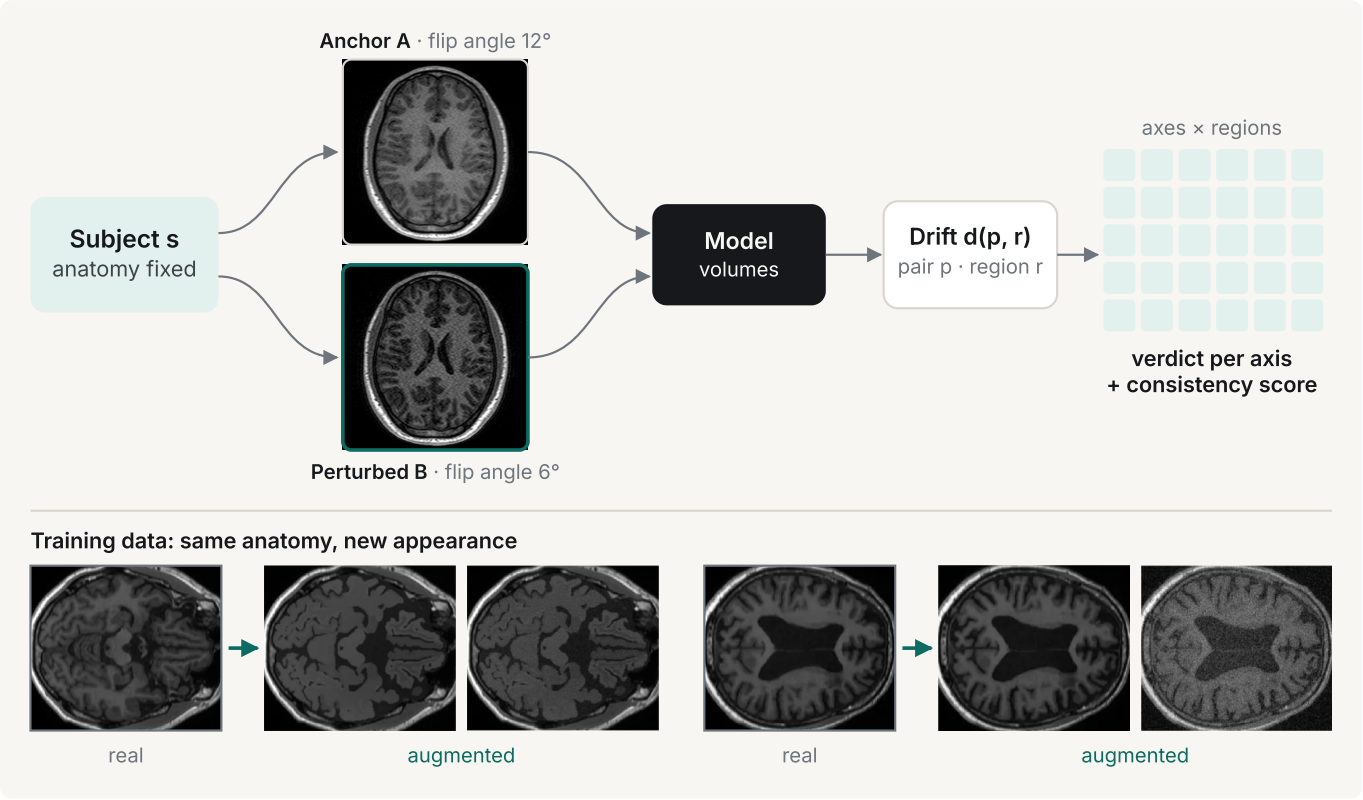
결과 figure는 탈출 디스크 하나에 대한 라벨 후보입니다. 함께 만든 pseudo-label 툴킷은 팀에서 쓰고 있습니다.

Image: public SPIDER lumbar-spine dataset.

Robustness · Evaluation · AIRS Medical

Brain volumetry 모델의 acquisition shift robustness 향상

held-out 평가에서 우수했던 모델이 동일한 환자의 scanner 설정이 다른 input에 대해 일정한 추론을 하지 못하는 문제 발생 → label-free benchmark로 원인을 찾고 physics-informed augmentation으로 해결



문제 같은 환자라도 scanner 설정에 따라 이미지의 특징이 달라질 수 있는데, 그때마다 모델의 출력이 달라졌습니다. held-out 평가로는 드러나지 않는 문제였습니다.

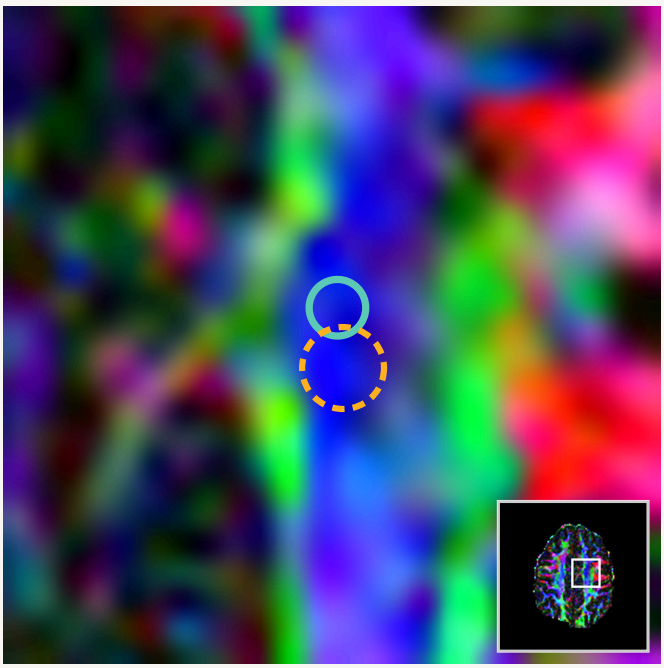
내가 한 일 failure를 직접 측정하기 위해 acquisition parameter를 하나만 바꾼 same-subject scan pair로 **label-free benchmark**를 만들었고, 오류의 원인을 tissue boundary의 intensity shortcut으로 좁혔습니다. 이어서 **physics-informed augmentation** 설계를 통해 모델 성능을 향상시켰습니다. 전 과정을 제가 주도했습니다.

결과 in-distribution 성능의 소폭 손실만으로 drift 대부분을 제거했고, **benchmark와 수정 모두 제품에 반영**됐습니다. 세부 내용은 회사 요청으로 비공개입니다.

Evaluation without ground truth · AIRS Medical

Ground truth가 없는 task에서 모델 평가

tract core 안의 어떤 위치든 똑같이 타당해 수작업 ROI를 ground truth로 쓸 수 없는 문제 발생 → 모델에 의해 샘플링된 값 자체를 평가하는 evaluation harness 구축



model radiologist

Overlap (Dice)

✗ 0.06 · "they disagree"

Measured value (mean FA)

✓ 0.423 vs 0.425

Same tract, a few mm apart:
both are valid placements.

Public IXI scan · right centrum semiovale

rescan stable? | same conclusion? | clinical signal? | fails silently?

문제 판독의 ROI와의 segmentation overlap으로 DTI 모델을 평가하면, 똑같이 타당한 다른 위치를 고른 모델이 감점됩니다. 예를 들어, 위 케이스에서는 Dice가 0.06으로 낮지만 mean FA는 0.423 vs 0.425로 큰 차이가 존재하지 않습니다.

내가 한 일 **모델에 의해 샘플링된 값 자체**를 평가하는 evaluation harness를 만들었습니다. rescan에서도 값이 안정적인지, 판독의와 같은 group-level 결론에 이르는지, clinical signal이 있는지, silent failure가 없는지를 확인하는 식으로, ground truth 없이도 평가할 수 있게 했습니다.

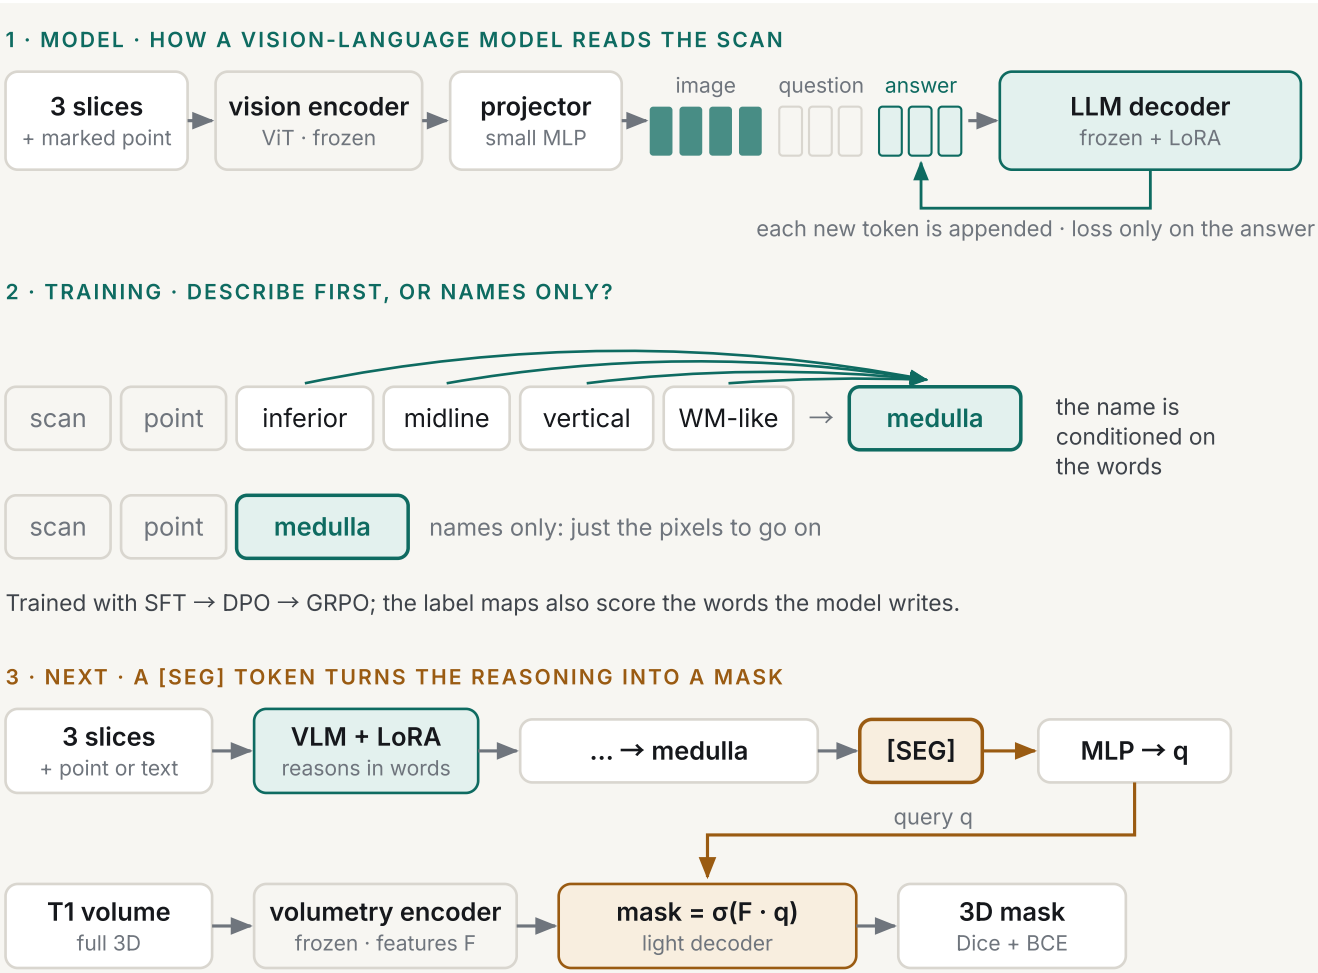
결과 해당 방법론을 통한 평가 결과가 **팀의 의사결정**을 바꿨습니다. **geometric accuracy가 더 높은 버전의 repeatability가 더 낮았고**, 팀은 geometry 최적화를 중단했습니다.

Image: public IXI dataset (CC BY-SA 3.0).

Side project · VLM · Post-training

Zero-shot brain anatomy segmentation을 위한 VLM reasoning 학습

구조 이름만 학습한 VLM은 학습하지 않은 구조를 다루기 어려운 문제 → anatomy의 특징을 근거로 추론하도록 학습해, 원하는 구조를 zero-shot으로 segmentation하는 것을 목표로 설계



아이디어 뇌 MRI의 한 점이 주어지면 위치, 좌우, 모양, 신호 강도와 같은 anatomy의 특징을 설명하는 단어들을 먼저 쓰고 나서 구조 이름을 답하는 모델을 설계했습니다. 학습 데이터를 위해 anatomy의 특징을 설명하는 단어들은 volumetry label map에서 계산되므로 모델이 쓴 단어마다 정답 여부를 채점할 수 있고, 같은 데이터를 fine-tuning target, preference pair, RL reward로 쓰도록 구성했습니다.

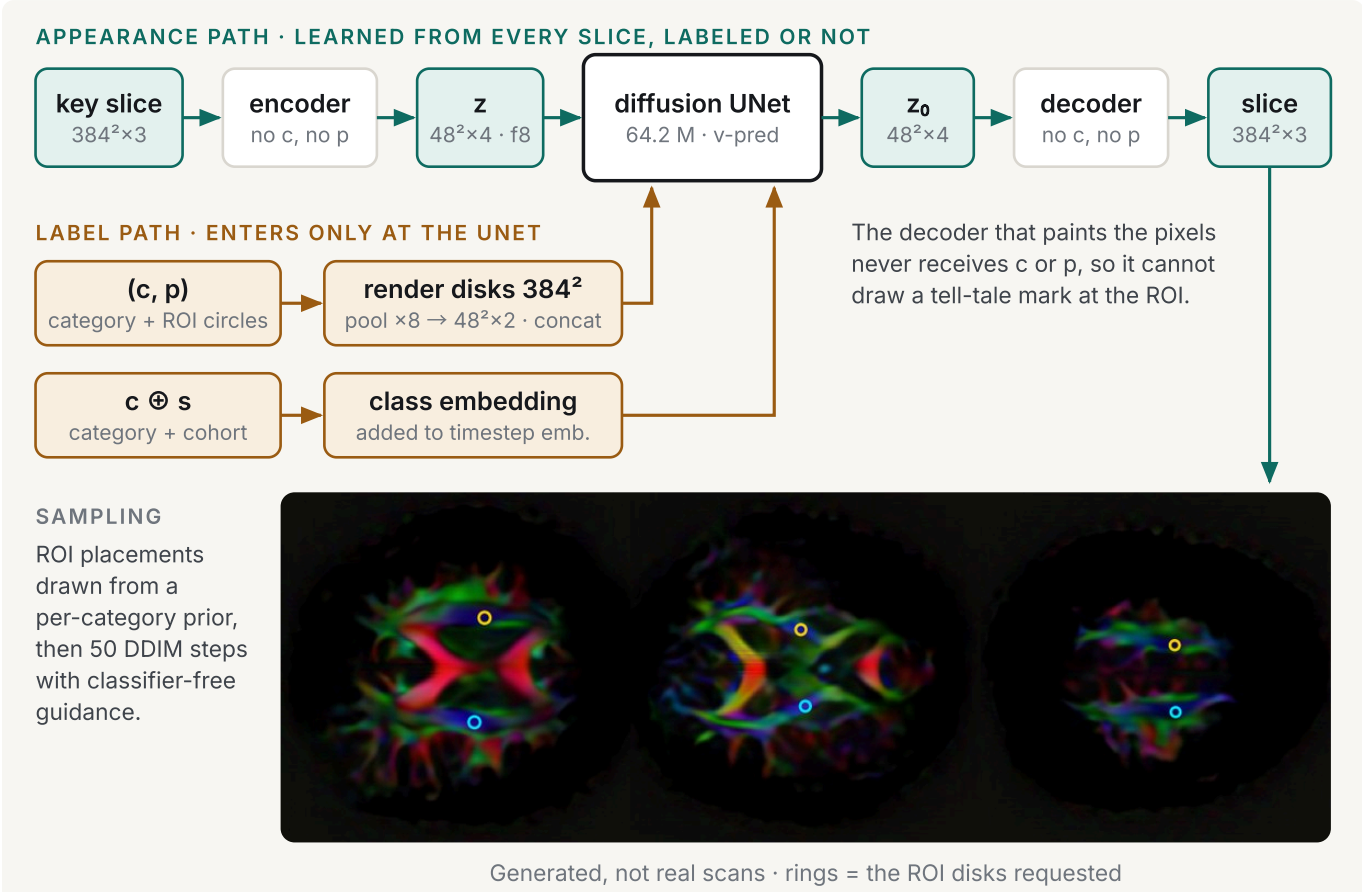
확장 이후 병변 묘사로 부위를 찾는 모델, reasoning으로 판정하는 모델, [SEG] token으로 3D mask를 출력하는 segmentation 모델로 확장할 계획입니다.

In progress · data pipeline과 baseline 완료

Side project · Generative model

label이 부족한 task를 위한 diffusion model 기반 labeled data 생성

수작업 라벨이 수백 개뿐이라 학습 데이터가 병목이 되는 문제 발생 → input과 label을 동시에 생성하는 two-stage generator를 구현



Generated, not real scans · rings = the ROI disks requested

배경 diffusion MRI slice에 ROI를 배치하는 모델의 수작업 라벨이 수백 개뿐이었습니다. 학습 데이터 병목을 해결해보고자 input과 label을 동시에 생성하기 위해, 지정한 ROI 주변으로 사실적인 color-FA slice를 생성하는 two-stage generator를 만들었습니다.

설계 slice를 latent로 압축하는 encoder·decoder와, ROI disk map과 category를 condition으로 latent를 생성하는 diffusion UNet의 2단계 구조입니다. 픽셀을 생성하는 decoder에는 라벨을 넣지 않아 label leakage를 막았습니다.

Paused · generator는 동작하며 아직 학습에는 쓰지 않음